

Travail pratique 3 : étude de cas Yelp

420-514-MV Automne 2025

Contexte :

Yelp est une application mobile qui fonctionne comme un annuaire en ligne pour rechercher divers types d'entreprises, en particulier des restaurants. Les utilisateurs peuvent filtrer leur recherche selon la région, le type de cuisine (comme Chinoise ou Italienne) ou la catégorie (ex. : Bar, Café). L'application fournit également des informations sur les horaires d'ouverture, les prix, etc. Les utilisateurs peuvent laisser des avis notés de 1 à 5 étoiles et donner des conseils ("Tips") sur les restaurants qu'ils visitent. En outre, Yelp propose un réseau social où les utilisateurs peuvent se lier d'amitié et marquer les avis comme "utile", "drôle" ou "cool". Certains utilisateurs sont désignés comme "Élites" en fonction de leur contribution à la plateforme.

Objectif :

En équipe de 3, vous devez créer un *dataset intégré* combinant plusieurs tables du Yelp Dataset, effectuer une analyse exploratoire et produire deux visualisations (dont une interactive) accompagnées d'une interprétation.

Source des données :

Yelp Dataset

The Yelp dataset is a subset of our businesses, reviews, and user data for use in connection with academic research. Available as JSON files, use it to teach students about databases, to learn NLP, or for sample production data while you learn how to make mobile apps.

✳ <https://www.yelp.com/dataset>

Yelp Dataset

A trove of reviews, businesses, users, tips, and check-in data!

<https://www.kaggle.com/datasets/yelp-dataset/yelp-dataset>



FIGURE 1 – Schéma décrivant les relations entre les composantes principales des données.

Sources : Maroun Haddad, Auxiliaires d'enseignement et Mohamed Bouguessa, Professeur cours Apprentissage automatique, Hivers 2021

Description des tables :

- **Utilisateurs** : Liste des utilisateurs incluant des détails tels que leur nom d'utilisateur et leur statut (Élite ou Régulier).
- **Avis** : Informations sur les avis rédigés pour chaque restaurant, incluant le nombre d'étoiles et les réactions d'autres utilisateurs ("useful", "funny", "cool"). Le texte des avis a été retiré pour réduire la taille de la base de données.
- **Conseils (tips)** : Informations sur les conseils écrits par les utilisateurs, avec le nombre de "compliments" reçus pour chaque conseil. Les conseils offrent des informations clés sur un restaurant (meilleur moment pour visiter, plats du

jour), sans être des avis complets. Le texte a également été retiré pour limiter la taille des données.

- **Check-in** : Contient les dates et heures de visite des restaurants.
- **Restaurants** : Liste des restaurants avec des détails comme le nom, l'emplacement, la note moyenne, et le statut (ouvert ou fermé définitivement).
- **Horaires** : Heures d'ouverture pour chaque restaurant sur les sept jours de la semaine.
- **Services** : Liste des services proposés par chaque restaurant (ex. : adapté pour les groupes, avec terrasse, livraison possible).
- **Catégories** : Catégories des restaurants (ex. : Petit-déjeuner & Brunch, Italien, Fruits de mer).

Table	Taille
Utilisateurs	748 247
Avis	207 3685
Conseils (tips)	416 803
Check-in	549 2282
Restaurants	34 268
Horaires	34 268
Services	34 268
Categories	89 945

Table 1 : Le nombre d'enregistrements dans chaque table.

Travail à réaliser

1. Création d'un dataset avec les attributs de base :

À partir des données des tables :

Table	Description	Variables principales à extraire
business	Restaurants avec coordonnées, catégories et attributs	<code>business_id</code> , <code>name</code> , <code>city</code> , <code>state</code> , <code>latitude</code> , <code>longitude</code> , <code>stars</code> , <code>review_count</code> , <code>attributes</code> , <code>categories</code>
review	Avis laissés par les utilisateurs	<code>business_id</code> , <code>user_id</code> , <code>stars</code> , <code>useful</code> , <code>funny</code> , <code>cool</code> , <code>date</code>
checkin	Dates et heures de visite	<code>business_id</code> , <code>date</code> (à convertir en nombre de check-ins)
user	Informations sur les utilisateurs	<code>user_id</code> , <code>name</code> , <code>review_count</code> , <code>average_stars</code> , <code>elite</code>
tip	Conseils courts donnés par les utilisateurs	<code>business_id</code> , <code>user_id</code> , <code>likes</code>
hours	Horaires d'ouverture	<code>business_id</code> , <code>hours</code> (convertir en indicateur d'ouverture moyenne)

Construisez un jeu de données (dataset) regroupant les informations suivantes en utilisant Pandas :

- **Qualité → moyenne étoiles** (`avg_stars`) : Donne une idée générale de la qualité du restaurant.
- **Ville** : Important pour la localisation du restaurant.
- **Popularité → nombre total d'avis** (`review_count_total`) : Indique la popularité du restaurant.
- **Nombre d'avis favorables** : Représente la proportion de clients satisfaits.
- **Satisfaction → ratio d'avis favorables** (`positive_ratio`) : Pourcentage des avis favorables, utile pour évaluer la satisfaction globale. Avis favorables (≥ 4 ★).
- **Activité → nombre total de check-ins** (`checkins_total`) : Mesure la fréquentation réelle du restaurant.
- **Chaîne** (`is_chain`) : Indique si le restaurant fait partie d'une chaîne, ce qui peut influencer les performances (`True` si même nom ≥ 3 fois).
- **Prix** (`price`) : Donne une idée du coût moyen du restaurant (Extraite de `attributes.RestaurantsPriceRange2`).

- **Communauté → nombre d'utilisateur élite (`elite_users_count`)** : Nombre d'utilisateurs "élite" ayant commenté le restaurant.
- **Disponibilité → Moyenne heures ouverture (`avg_open_hours`)** : Moyenne des heures d'ouverture par jour (calculée à partir de `hours`)

2. Création de deux visualisations :

1. Graphique statique (ex. : barres ou histogramme)

- Exemples :
 - Top 10 des catégories par note moyenne
 - Répartition des prix par ville
- Outils : `matplotlib` ou `seaborn`

2. Graphique interactif

- Exemples :
 - Scatter "nombre d'avis vs ratio favorable"
 - Carte des meilleurs restaurants par ville

Chaque graphique doit comporter un titre, des axes clairs et une interprétation (3 à 5 lignes).

3. Analyse et interprétation

- Rédigez **3 à 5 observations clés** à partir de vos graphiques.

Exemples :

- Les restaurants ayant plus de 500 avis ont un ratio de satisfaction stable autour de 0,8.

Remise et évaluation

Le travail sera évalué sur la **qualité de l'analyse, la rigueur du traitement des données et la clarté des visualisations**.

Assurez-vous que votre code est bien documenté, vos calculs reproductibles et votre réflexion analytique bien justifiée.

 **Échéance** : 22 novembre 2025

 **Équipe** : 3 personnes

 **Remise** : sur Léa

Livrables à remettre

Chaque équipe doit déposer **un seul dossier compressé (.zip)** contenant les éléments suivants :

Fichier	Contenu attendu
<code>tp_yelp.ipynb</code>	Notebook complet avec le code, les graphiques et les commentaires explicatifs
<code>restaurants_features.csv</code>	Dataset final intégré avec toutes les colonnes calculées
<code>README.md</code>	Description du projet, rôles de chaque membre, instructions d'exécution
(optionnel) <code>rapport_yelp.pdf</code>	Export du notebook en PDF ou HTML pour une lecture rapide

Le notebook doit pouvoir être exécuté du début à la fin sans erreur.

Barème

Section	Points	Détails
Préparation et nettoyage des données	15	Filtrage cohérent, gestion des valeurs manquantes
Construction du dataset final	25	Toutes les colonnes demandées bien calculées
Visualisation statique	10	Lisibilité, pertinence, choix graphique
Visualisation interactive	20	Interactivité, originalité, utilité
Analyse et interprétation	15	Observations pertinentes, argumentées
Qualité du code (lisibilité, commentaires, structure Notebook)	10	Variables claires, étapes bien séparées
Collaboration et documentation (README, répartition claire)	5	Travail équilibré, traçabilité du rôle de chacun

Bonus possibles (+5 pts)

- Ajouter une **3e visualisation** (carte ou corrélation)
- Intégrer un **filtre interactif** (ville ou prix)
- Utiliser une **bibliothèque de dashboard** (Dash, Streamlit, Voilà)

Conseils :

Données à utiliser :

- Pour pouvoir tester rapidement vous pouvez créer des sous-ensembles de données au lieu de tester avec toutes les données d'une table en créant un dataset de par exemple 100 enregistrements au lieu d'utiliser le dataframe contenant tous les enregistrements de la table chargée.
- Pour éviter les temps d'exécution trop longs :
 - Limitez-vous à **3 villes maximum** (exemples : *Phoenix, Toronto, Las Vegas*).
 - Vous pouvez créer des **sous-échantillons** (ex. : 1 000 à 5 000 restaurants, 50 000 à 100 000 avis).
 - Si nécessaire, vous pouvez utiliser uniquement un **sous-ensemble des colonnes** dans certaines tables.
- Vérifiez la cohérence des types (`int` , `float` , `datetime`).
- Sauvegardez régulièrement votre DataFrame intermédiaire (`to_csv`) pour éviter de tout recalculer.
- Assurez-vous que votre Notebook s'exécute **sans erreur du début à la fin**.
- Bien répartir les tâches entre les membre de l'équipe. La collaboration est importante.
 - Répartition suggérée des rôles :

Membre	Tâches principales
Personne 1 – Préparation des données	Charger, nettoyer et filtrer les tables (<code>business</code> , <code>user</code> , <code>review</code> , <code>checkin</code> , <code>tip</code> , <code>hours</code> , etc.)

Membre	Tâches principales
Personne 2 – Intégration et calcul des indicateurs	Effectuer les jointures, calculer les indicateurs (<code>positive_ratio</code> , <code>checkins_total</code> , <code>avg_open_hours</code> , etc.)
Personne 3 – Visualisations et interprétation	Créer 2 graphiques (1 statique, 1 interactif) et rédiger l'analyse finale

- Structure suggérée du Notebook :
 1. 🗺️ Introduction TP, membres de l'équipe.
 2. 📁 Chargement des données
 3. 🧹 Nettoyage et préparation
 4. 🔗 Intégration et calcul des indicateurs
 5. 📊 Visualisations
 6. 🧠 Analyse et conclusions
 7. 💾 Export du dataset final